UNIVERSITÉ
DE REIMS
CHAMPAGNE-ARDENNE

Réseaux de Neurones et Traitement d'Images en Temps Réel

Brahim Yahiaoui
byahiaoui@nexyad.net

Présentation du cours

- Introduction et prise en main de OpenCV
- Les réseaux de neurones dans l'image
- Traitements des signaux en temps réel

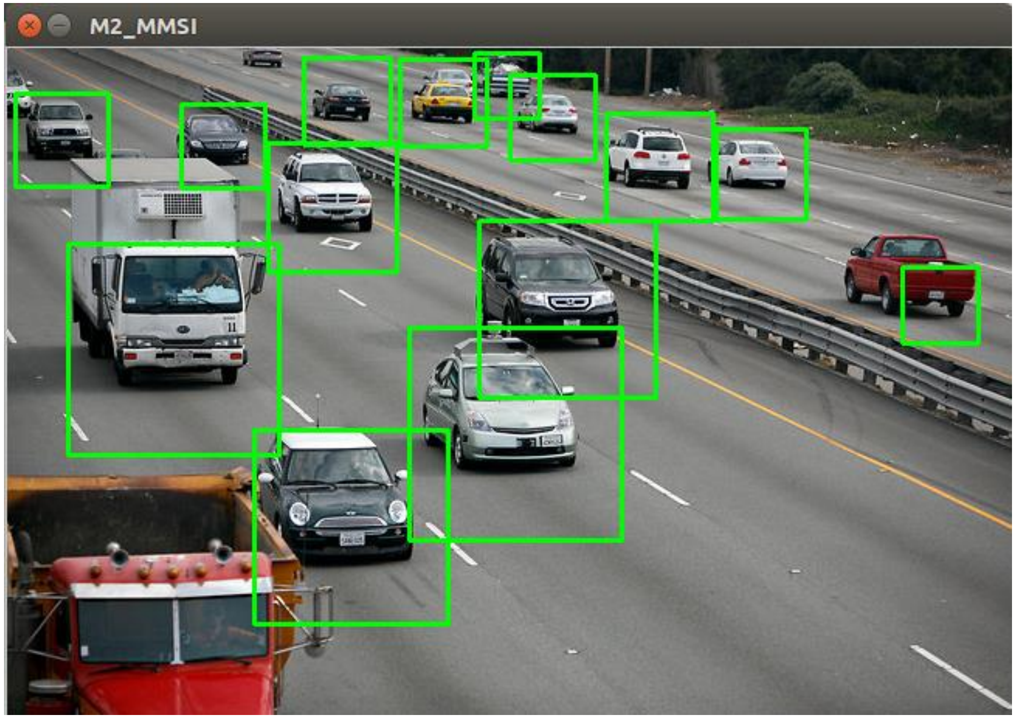

UNIVERSITÉ
DE REIMS
CHAMPAGNE-ARDENNE

Les réseaux de neurones dans l'image

UNIVERSITÉ
DE REIMS
CHAMPAGNE-ARDENNE

Introduction aux réseaux de neurones

Les réseaux de neurones

- Méthode inspirée du fonctionnement des neurones biologiques
- Utilisés pour élaborer des algorithmes capables d’apprendre

- Domaines d’application :
  - Reconnaissance optique de caractères (OCR)
  - Biologie : Classifications d’espèces animales
  - Economie : Classification d’entreprises et prédiction d’échec
  - Réseaux sociaux : Analyse sémantique de phrases sur internet pour la publicité ciblée ou la sécurité
  - Vision robotique : Détection d’obstacles et étiquetage

Modèle du neurone formel

- Modélisation par McCulloch et Pitts (1943) d’un neurone

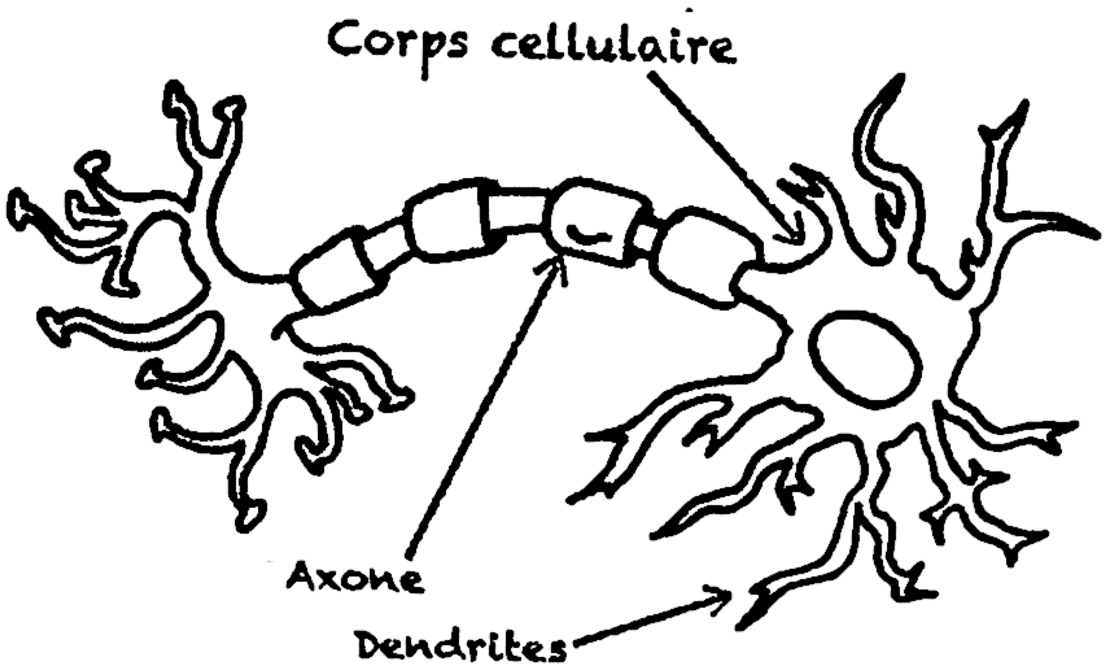

Modèle du neurone formel

- Modélisation **mathématique** par McCulloch et Pitts (1943) d'un neurone **par un perceptron dit simple**

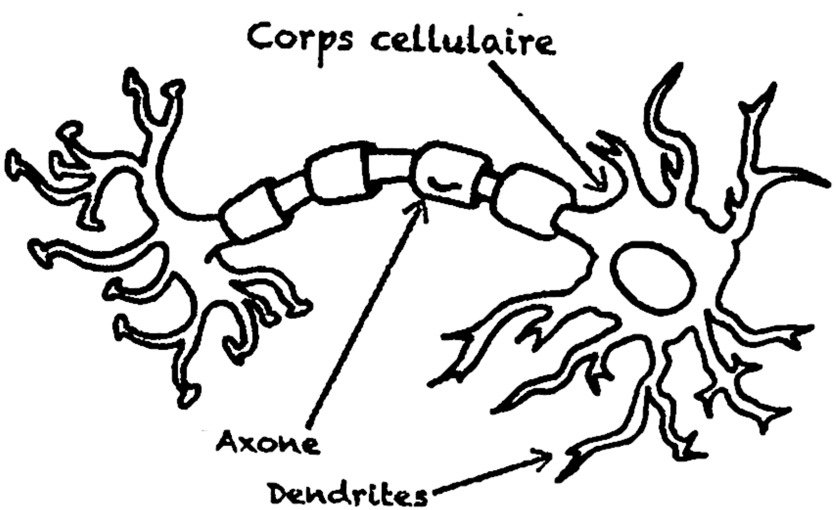

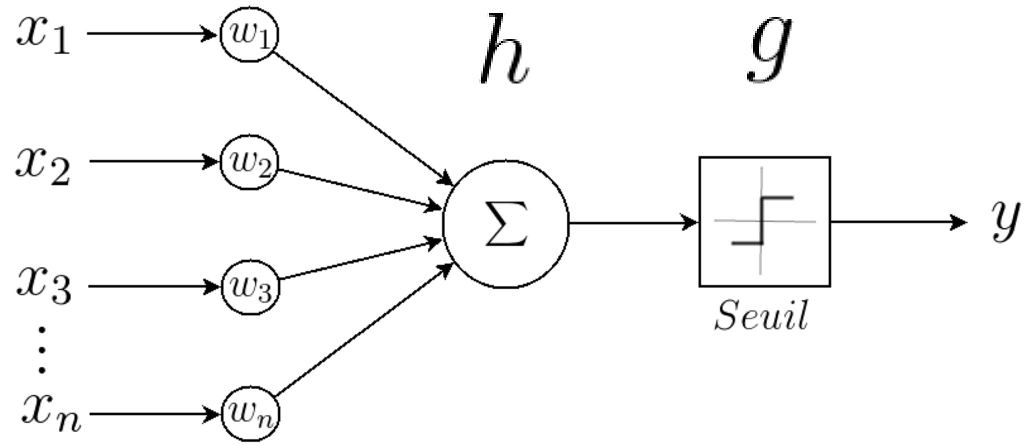

$$y = g(h(X, W)) = g\left(\sum_{i=1}^{n} w_i x_i\right)$$

Fonction d'activation (seuil)

Posons $x' = h(X, W)$

$$y = g_s(x') = g_s\left(\sum_{i=1}^{n} w_i x_i\right)$$

où g_s est la fonction de Heaviside, et s le seuil.

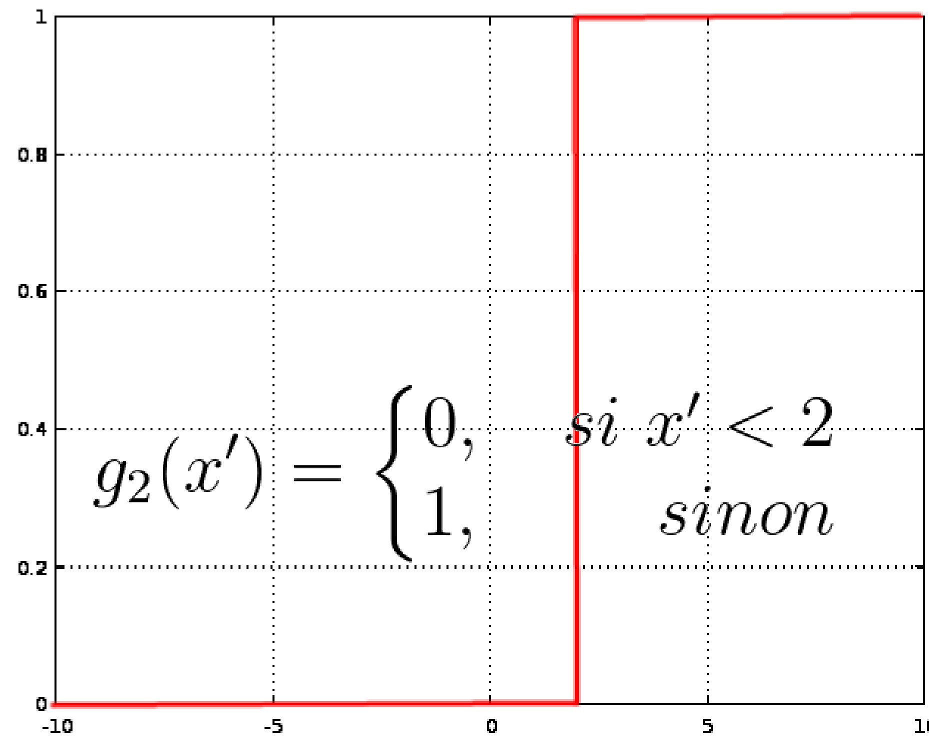

$$g_2(x') = \begin{cases} 0, & si\ x' < 2 \\ 1, & sinon \end{cases}$$

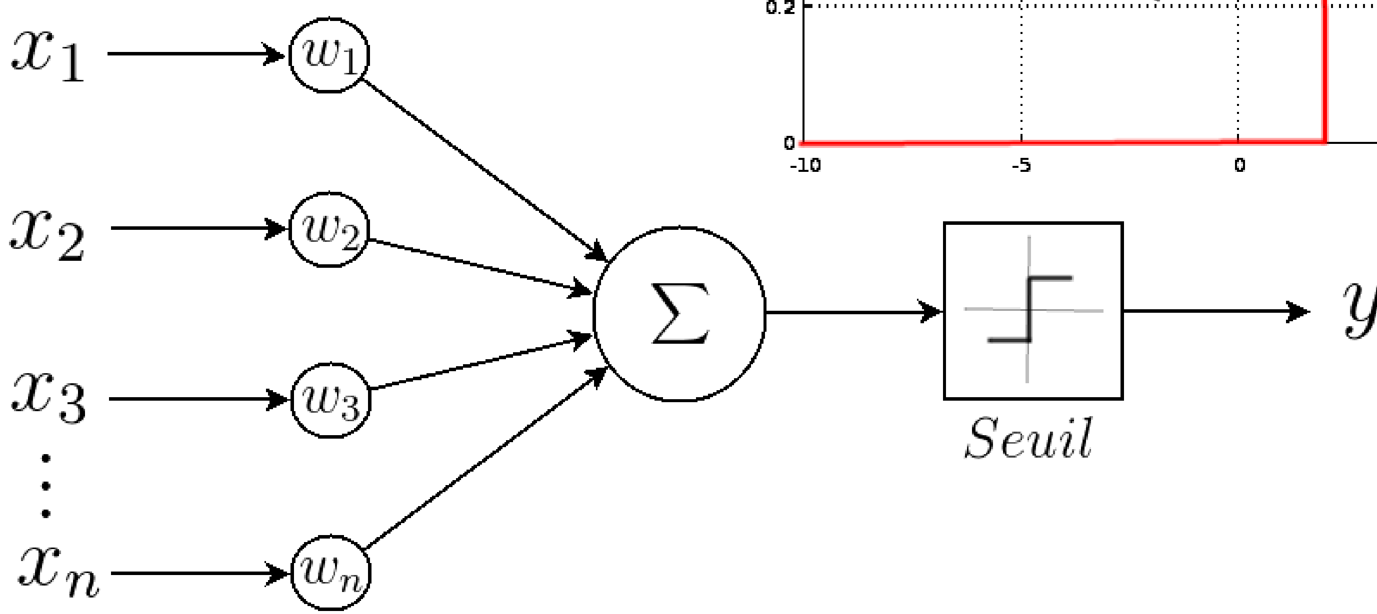

Fonction d'activation (seuil)

$$g_s(x') = g_0\left(\sum_{i=1}^{n} w_i x_i + s\right)$$

En posant $w_0 = s$ et $x_0 = 1$

$$g_s(x') = g_0\left(\sum_{i=0}^{n} w_i x_i\right)$$

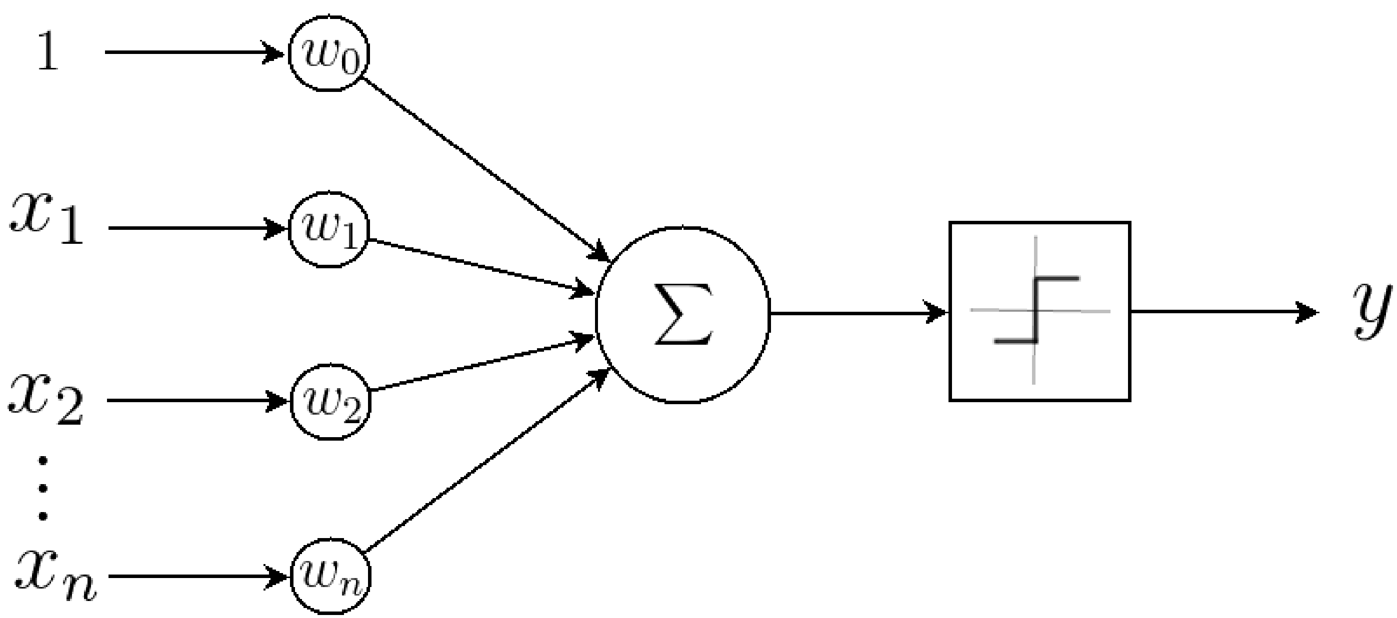

Fonction d'activation

Les fonctions suivantes peuvent être utilisées comme fonction d’activation resp. par ordre de recommandation :

1. La fonction de Heaviside
2. La tangente hyperbolique
3. La fonction sigmoïde
4. La fonction rectifieur ReLU max(0, x)

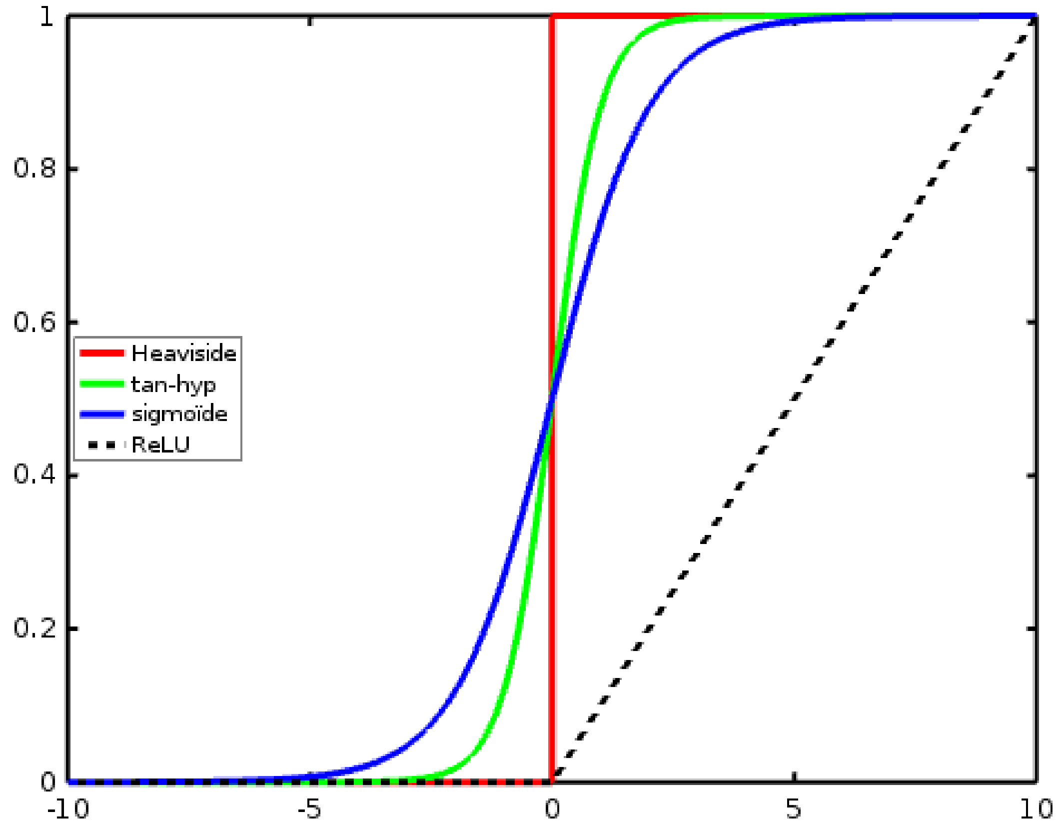

Représentation d'un neurone en théorie des graphes

- Nous utiliserons à partir de ce slide la nouvelle représentation du neurone
- La représentation :

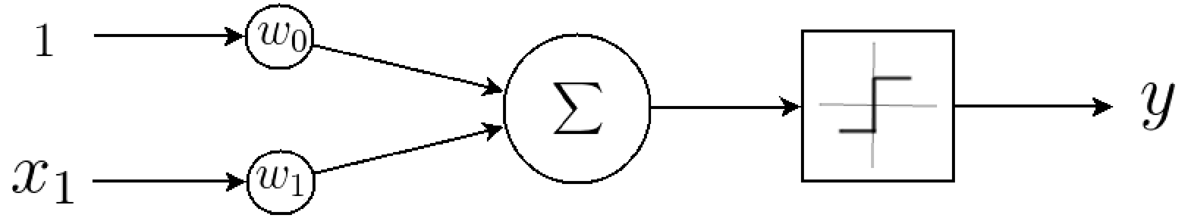

- Devient :

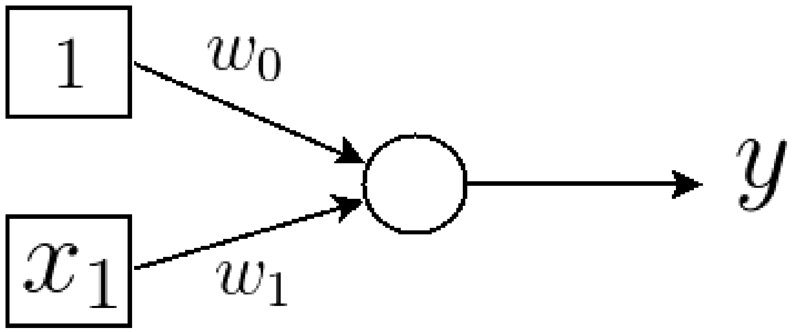

Perceptron multi-couches

- Perceptron simple
  - Régression linéaire
  - Moindres carrés
- Perceptrons mullti-couches
  - Résolution de problèmes non linéaires
  - Généralisable en réseaux de neurones à multi-couches

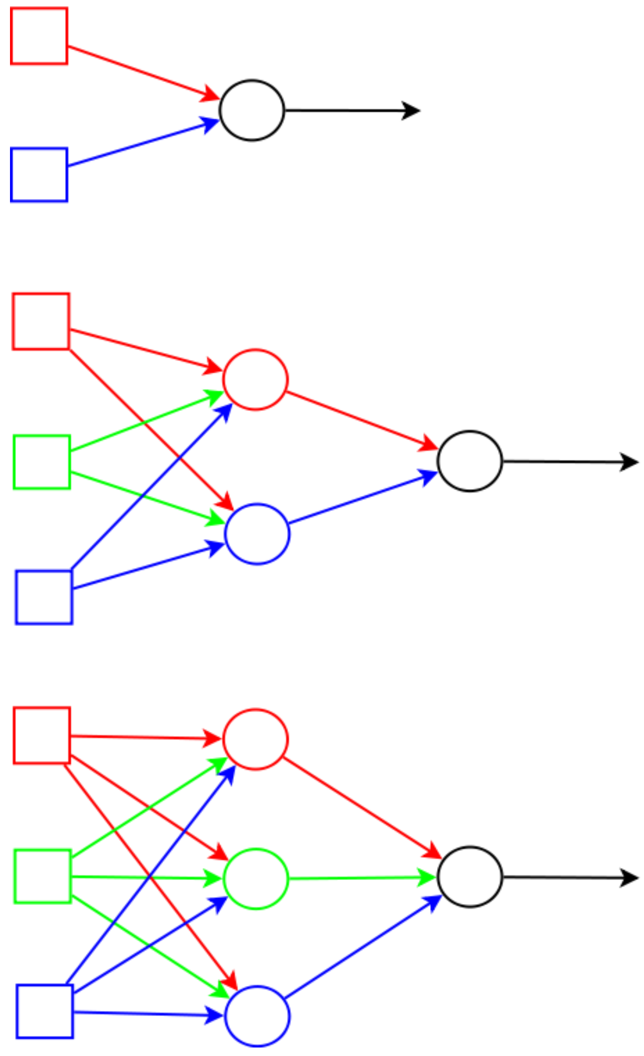

Modèle de réseaux de neurones à multi-couches

- Exemple relativement généralisé des graphes de réseaux de neurones à multi-couches

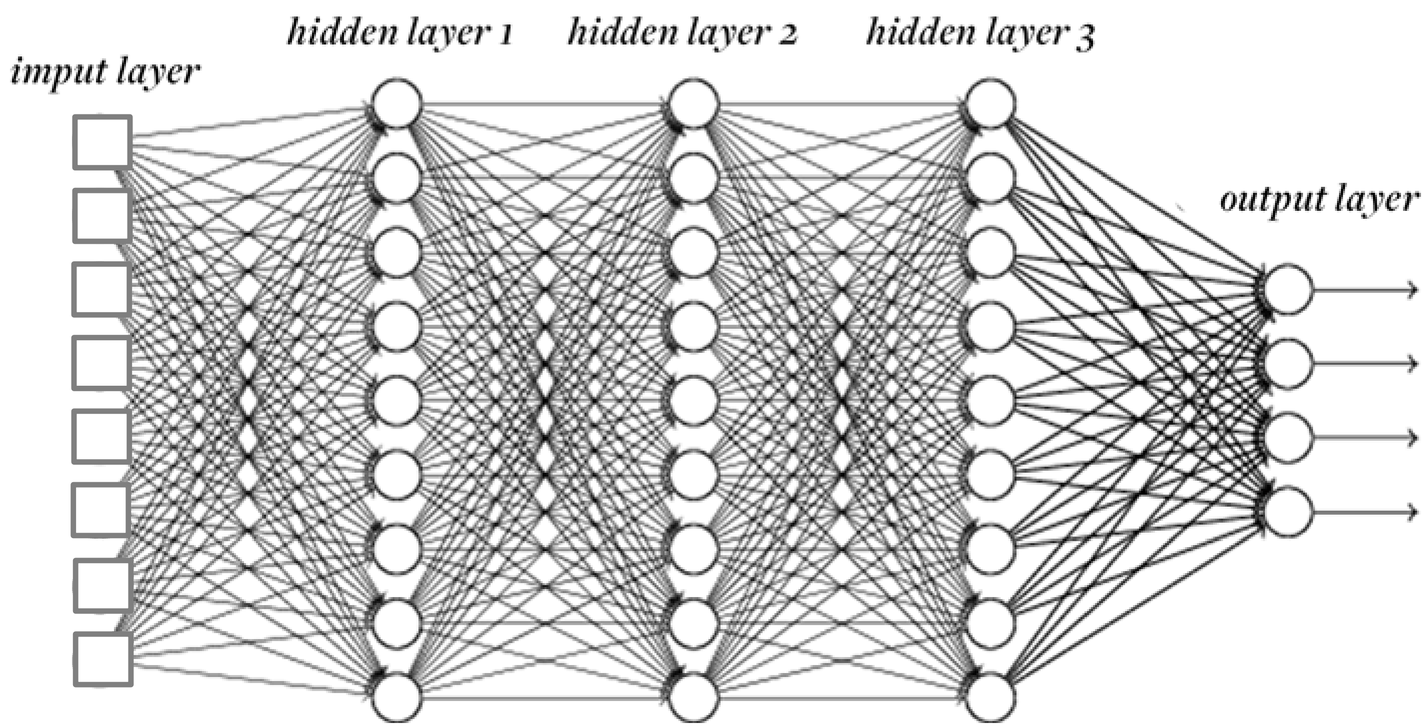

Propagation dans un réseau de neurones

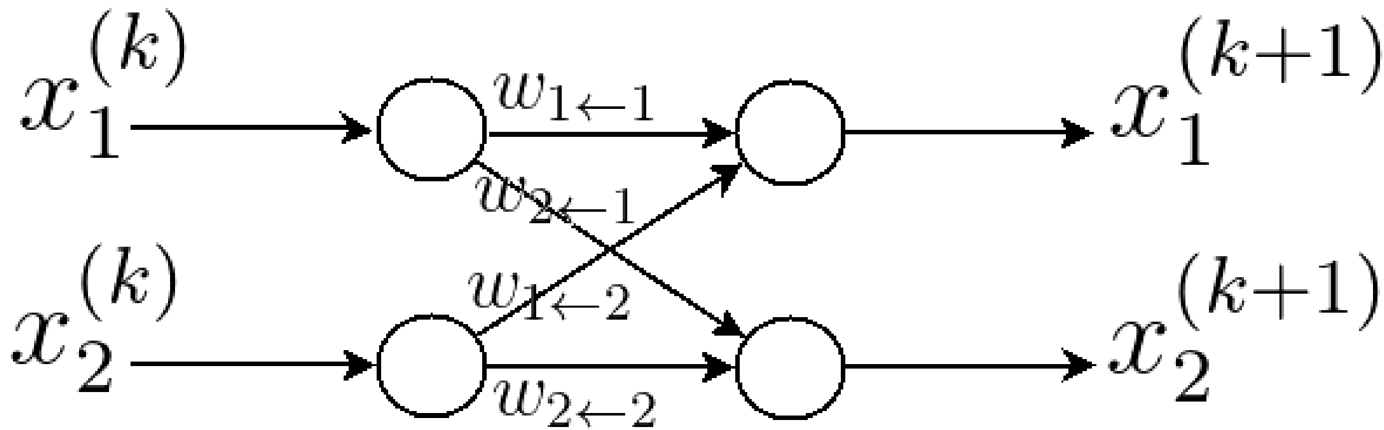

$$\begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \end{pmatrix} = g\begin{pmatrix} \sum_{j=1}^{2} w_{1\leftarrow j} x_j^{(k)} \\ \sum_{j=1}^{2} w_{2\leftarrow j} x_j^{(k)} \end{pmatrix}$$

Propagation dans un réseau de neurones

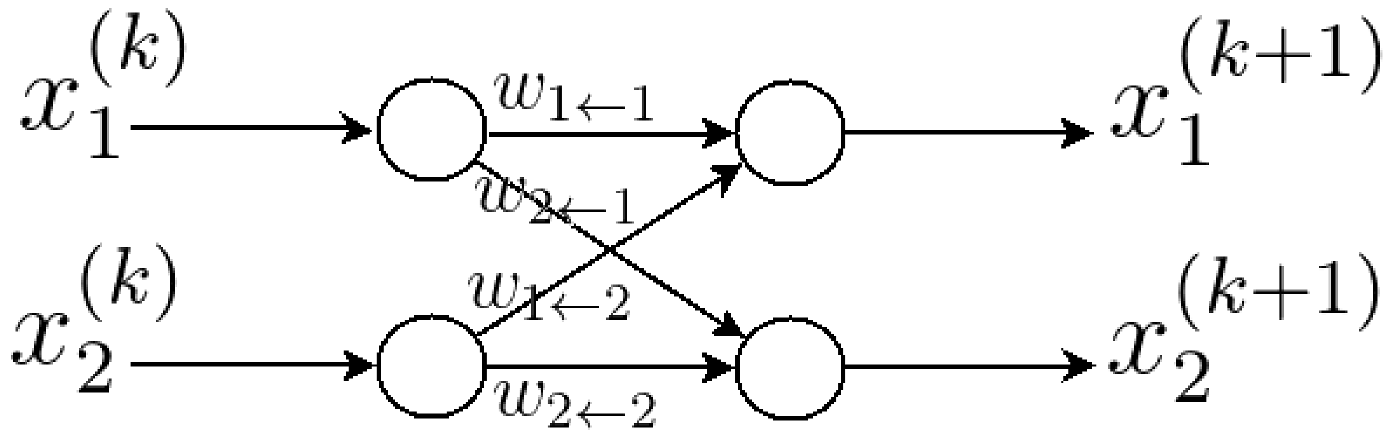

$$\begin{aligned}
\begin{pmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \end{pmatrix} &= g\left(\begin{matrix} \sum_{j=1}^{2} w_{1\leftarrow j} x_j^{(k)} \\ \sum_{j=1}^{2} w_{2\leftarrow j} x_j^{(k)} \end{matrix}\right) \\
&= g\left(\begin{pmatrix} w_{1\leftarrow 1} & w_{1\leftarrow 2} \\ w_{2\leftarrow 1} & w_{2\leftarrow 2} \end{pmatrix} \begin{pmatrix} x_1^{(k)} \\ x_2^{(k)} \end{pmatrix} \right)
\end{aligned}$$

Propagation dans un réseau de neurones

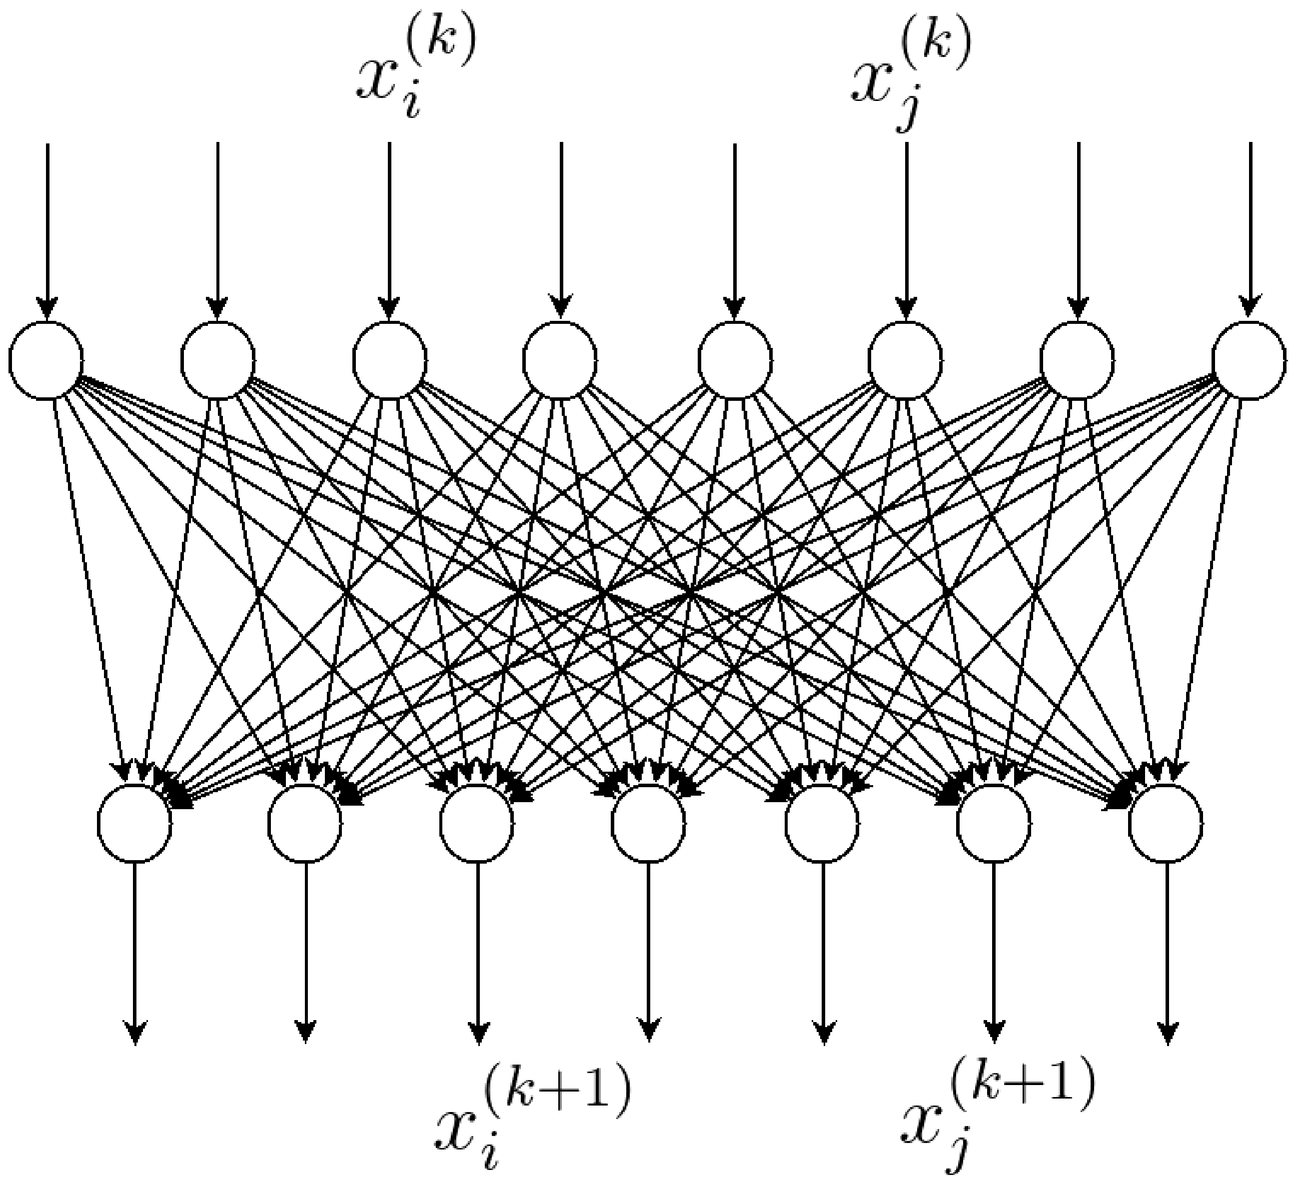

Propagation dans un réseau de neurones

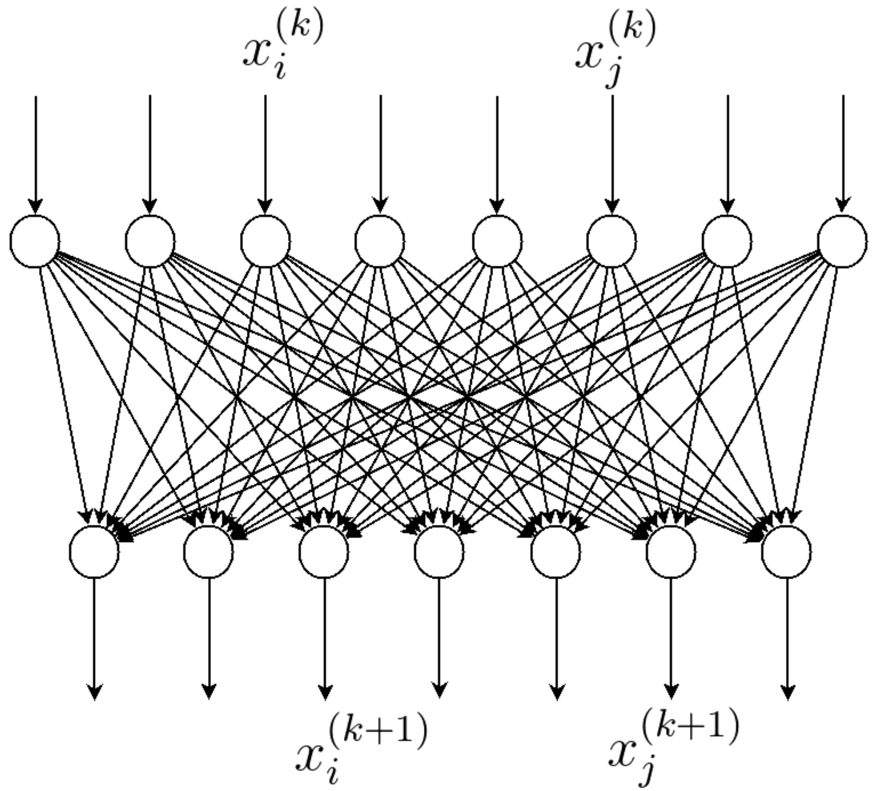

$$\begin{pmatrix} \vdots \\ x_i^{(k+1)} \\ \vdots \\ x_j^{(k+1)} \\ \vdots \end{pmatrix} = g\left(\begin{pmatrix} \ddots & \cdots & \cdots & \cdots & \cdots \\ \vdots & w_{i\leftarrow i} & \cdots & w_{i\leftarrow j} & \cdots \\ \vdots & \vdots & \ddots & \cdots & \cdots \\ \vdots & w_{j\leftarrow i} & \vdots & w_{j\leftarrow j} & \cdots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{pmatrix} \begin{pmatrix} \vdots \\ x_i^{(k)} \\ \vdots \\ x_j^{(k)} \\ \vdots \end{pmatrix} \right)$$

Apprentissage et reconnaissance

- Phase d’apprentissage supervisé
  - **Pré-requis : base de données indexés par types dite base d’apprentissage**
  - Propagation de de la donnée d’entrée
  - Comparé la donnée de sortie avec le résultat attendu
  - Rétro-propagation de l’erreur pour la correction de poids synaptiques
- Phase de validation (validation de la reconnaissance)
  - **Pré-requis : une base de données différente de la base d’apprentissage dite base de tests**
  - Evaluer l’efficience = nombre d’erreurs / nombre de tests
  - Si le pourcentage est bas. refaire l’apprentissage.

Exemple avec une couche

- Prenons l’exemple suivant

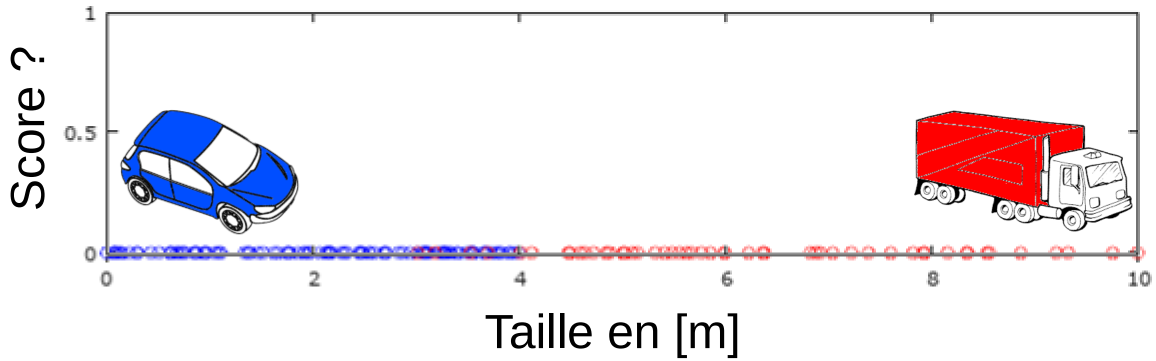

- On modélise de réseau de neurones suivant

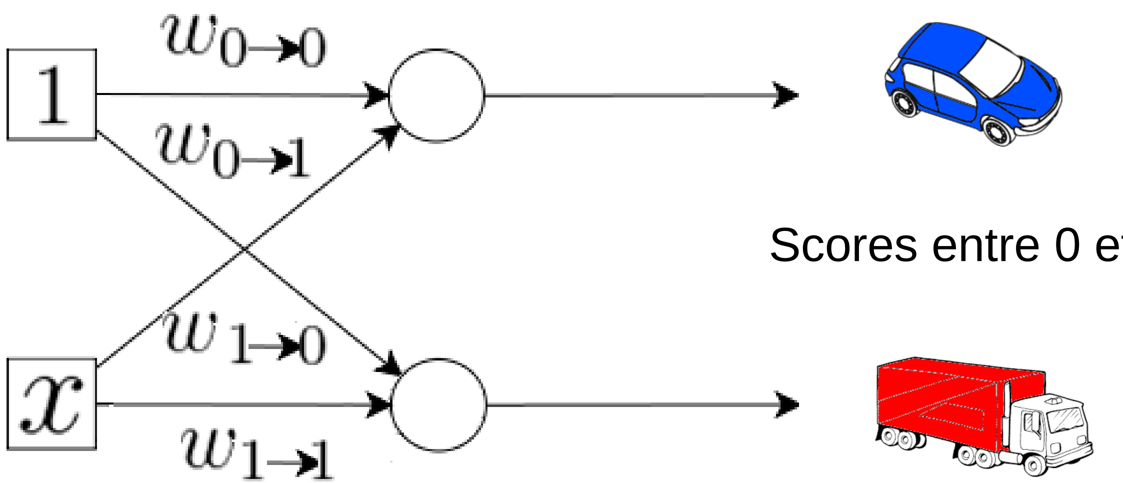

Exemple avec une couche

- Prenons l'exemple suivant

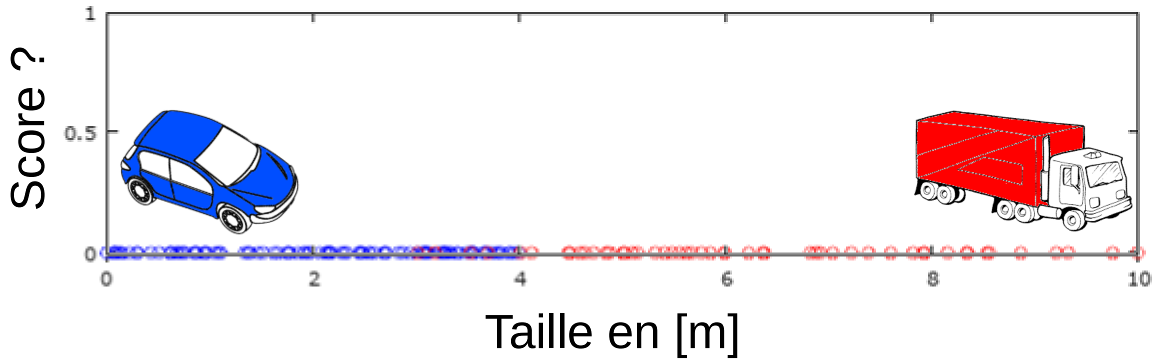

- On obtient les sigmoïdes suivantes

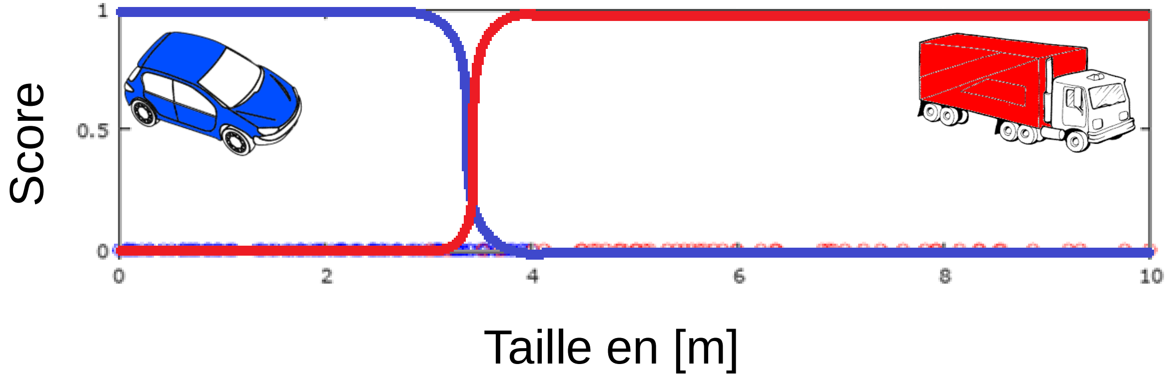

Un peu d'histoire

1940 : La machine de Turing
1943 : Le neurone formel (McCulloch & Pitts)
1948 : Les réseaux d'automates (Von Neuman)
1949 : Première règle d'apprentissage (Hebb)
1958-62 : Le perceptron (Rosenblatt)
1960 : L'adaline (Widrow & Hoff)
1969 : *Perceptrons* (Minsky & Papert)

➔ les limites du Perceptron
➔ besoin d'architectures + complexes,

Comment effectuer l'apprentissage ? On ne sait pas !

1974 : Rétropropagation (Werbos)

➔ pas de succès !?!?

1986 : Rétropropagation (Rumelhart & McClelland)
1990 : « Société de l'Information »

➔ nouvelles applications

- recherche/filtrage d'information dans le Web
- extraction d'information / veille technologique
- multimedia (indexation, …)
- data mining

Un peu d’histoire

- Ensuite, le Deep-Learning est arrivé

2012 Teams	%error
Supervision (Toronto)	15.3
ISI (Tokyo)	26.1
VGG (Oxford)	26.9
XRCE/INRIA	27.0
UvA (Amsterdam)	29.6
INRIA/LEAR	33.4

2013 Teams	%error
Clarifai (NYU spinoff)	11.7
NUS (singapore)	12.9
Zeiler-Fergus (NYU)	13.5
A. Howard	13.5
OverFeat (NYU)	14.1
UvA (Amsterdam)	14.2
Adobe	15.2
VGG (Oxford)	15.2
VGG (Oxford)	23.0

2014 Teams	%error
GoogLeNet	6.6
VGG (Oxford)	7.3
MSRA	8.0
A. Howard	8.1
DeeperVision	9.5
NUS-BST	9.7
TTIC-ECP	10.2
XYZ	11.2
UvA	12.1

Concours ImageNet 2012-2014

Rétro-propagation (exemple de fonction coût)

- Fonction coût qu'on souhaite minimiser pour un perceptron à *m* couches :

$$J^{(m)} = \frac{1}{2}\sum_{i=0}^{n^{(m)}}(x_i^{(m)} - y_i)^2$$

- Résolution par une méthode de descente :

$$w_{ij} \leftarrow w_{ij} - \eta \frac{\partial J}{\partial w_{ij}}$$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial w_{ij}^{(m)}}$$

`avec` $a_i^{(m)} = \sum_{k=0}^{n^{(m-1)}} w_{ik} x_k^{(m-1)}$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial w_{ij}^{(m)}}$$

avec $a_i^{(m)} = \sum_{k=0}^{n^{(m-1)}} w_{ik} x_k^{(m-1)}$

$$\frac{\partial J}{\partial x_i^{(m)}} = \frac{\partial J^{(m)}}{\partial x_i^{(m)}}$$

$$\boxed{(x_i^{(m)} - y_i)}$$

$$J^{(m)} = \frac{1}{2} \sum_{i=0}^{n^{(m)}} (x_i^{(m)} - y_i)^2$$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial w_{ij}^{(m)}}$$

avec $a_i^{(m)} = \sum_{k=0}^{n^{(m-1)}} w_{ik} x_k^{(m-1)}$

$$\frac{\partial J}{\partial x_i^{(m)}} = \frac{\partial J^{(m)}}{\partial x_i^{(m)}}$$

$$\boxed{(x_i^{(m)} - y_i)}$$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial w_{ij}^{(m)}}$$

avec $a_i^{(m)} = \sum_{k=0}^{n^{(m-1)}} w_{ik} x_k^{(m-1)}$

$$\frac{\partial J}{\partial x_i^{(m)}} = \frac{\partial J^{(m)}}{\partial x_i^{(m)}}$$

$$x_i^{(m)} = g(a_i^{(m)})$$

$$\boxed{(x_i^{(m)} - y_i)}$$

$$\boxed{g'(a_i^{(m)})}$$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial w_{ij}^{(m)}}$$

avec $a_i^{(m)} = \sum_{k=0}^{n^{(m-1)}} w_{ik} x_k^{(m-1)}$

$$\frac{\partial J}{\partial x_i^{(m)}} = \frac{\partial J^{(m)}}{\partial x_i^{(m)}}$$

$$x_i^{(m)} = g(a_i^{(m)})$$

$$\boxed{x_j^{(m-1)}}$$

$$\boxed{(x_i^{(m)} - y_i)}$$

$$\boxed{g'(a_i^{(m)})}$$

Rétro-propagation de la dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial w_{ij}^{(m)}}$$

$$\frac{\partial J}{\partial w_{ij}^{(m)}} = \frac{\partial J}{\partial x_i^{(m)}} \frac{\partial x_i^{(m)}}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial w_{ij}^{(m)}}$$

avec $a_i^{(m)} = \sum_{k=0}^{n^{(m-1)}} w_{ik} x_k^{(m-1)}$

$$\frac{\partial J}{\partial x_i^{(m)}} = \frac{\partial J^{(m)}}{\partial x_i^{(m)}}$$

$$x_i^{(m)} = g(a_i^{(m)})$$

$$x_j^{(m-1)}$$

$$(x_i^{(m)} - y_i)$$

$$g'(a_i^{(m)})$$

$$\boxed{\frac{\partial J}{\partial w_{ij}^{(m)}} = (x_i^{(m)} - y_i) g'(a_i^{(m)}) x_j^{(m-1)}}$$

Rétro-propagation de l'avant dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \frac{\partial J}{\partial x_i^{(m-1)}} \frac{\partial x_i^{(m-1)}}{\partial a_i^{(m-1)}} \frac{\partial a_i^{(m-1)}}{\partial w_{ij}^{(m-1)}}$$

Rétro-propagation de l'avant dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \frac{\partial J}{\partial x_i^{(m-1)}} \frac{\partial x_i^{(m-1)}}{\partial a_i^{(m-1)}} \frac{\partial a_i^{(m-1)}}{\partial w_{ij}^{(m-1)}}$$

$$x_i^{(m-1)} = g(a_i^{(m-1)})$$

$$a_i^{(m-1)} = \sum_{k=0}^{n^{(m-2)}} w_{ik} x_k^{(m-2)}$$

$$g'(a_i^{(m-1)})$$

$$x_j^{(m-2)}$$

Rétro-propagation de l'avant dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \frac{\partial J}{\partial x_i^{(m-1)}} \frac{\partial x_i^{(m-1)}}{\partial a_i^{(m-1)}} \frac{\partial a_i^{(m-1)}}{\partial w_{ij}^{(m-1)}}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial x_i^{(m-1)}}$$

$$x_i^{(m-1)} = g(a_i^{(m-1)})$$

$$g'(a_i^{(m-1)})$$

$$a_i^{(m-1)} = \sum_{k=0}^{n^{(m-2)}} w_{ik} x_k^{(m-2)}$$

$$x_j^{(m-2)}$$

Rétro-propagation de l'avant dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \frac{\partial J}{\partial x_i^{(m-1)}} \frac{\partial x_i^{(m-1)}}{\partial a_i^{(m-1)}} \frac{\partial a_i^{(m-1)}}{\partial w_{ij}^{(m-1)}}$$

$$a_i^{(m-1)} = \sum_{k=0}^{n^{(m-2)}} w_{ik} x_k^{(m-2)}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial x_i^{(m-1)}} \qquad x_i^{(m-1)} = g(a_i^{(m-1)})$$

$$g'(a_i^{(m-1)}) \qquad x_j^{(m-2)}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} w_{ij}^{(m)}$$

Rétro-propagation de l’avant dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \frac{\partial J}{\partial x_i^{(m-1)}} \frac{\partial x_i^{(m-1)}}{\partial a_i^{(m-1)}} \frac{\partial a_i^{(m-1)}}{\partial w_{ij}^{(m-1)}}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial x_i^{(m-1)}}$$

$$x_i^{(m-1)} = g(a_i^{(m-1)})$$

$$a_i^{(m-1)} = \sum_{k=0}^{n^{(m-2)}} w_{ik} x_k^{(m-2)}$$

$$g'(a_i^{(m-1)})$$

$$x_j^{(m-2)}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} w_{ij}^{(m)}$$

$$\boxed{\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \left(\sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} w_{ij}^{(m)} \right) g'(a_i^{(m-1)}) x_j^{(m-2)}}$$

Rétro-propagation de l’avant dernière couche

$$\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \frac{\partial J}{\partial x_i^{(m-1)}} \frac{\partial x_i^{(m-1)}}{\partial a_i^{(m-1)}} \frac{\partial a_i^{(m-1)}}{\partial w_{ij}^{(m-1)}}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} \frac{\partial a_i^{(m)}}{\partial x_i^{(m-1)}}$$

$$x_i^{(m-1)} = g(a_i^{(m-1)})$$

$$a_i^{(m-1)} = \sum_{k=0}^{n^{(m-2)}} w_{ik} x_k^{(m-2)}$$

$$\frac{\partial J}{\partial x_i^{(m-1)}} = \sum_{i=0}^{n^{(m)}} \frac{\partial J}{\partial a_i^{(m)}} w_{ij}^{(m)}$$

$$g'(a_i^{(m-1)})$$

$$x_j^{(m-2)}$$

Déduire ?

$$\boxed{\frac{\partial J}{\partial w_{ij}^{(m-1)}} = \left(\sum_{i=0}^{n^{(m)}} \boxed{\frac{\partial J}{\partial a_i^{(m)}}} w_{ij}^{(m)} \right) g'(a_i^{(m-1)}) x_j^{(m-2)}}$$

UNIVERSITÉ
DE REIMS
CHAMPAGNE-ARDENNE

Les réseaux de neurones dans le traitement d'images
-Apprentissage profond-

Apprentissage profond

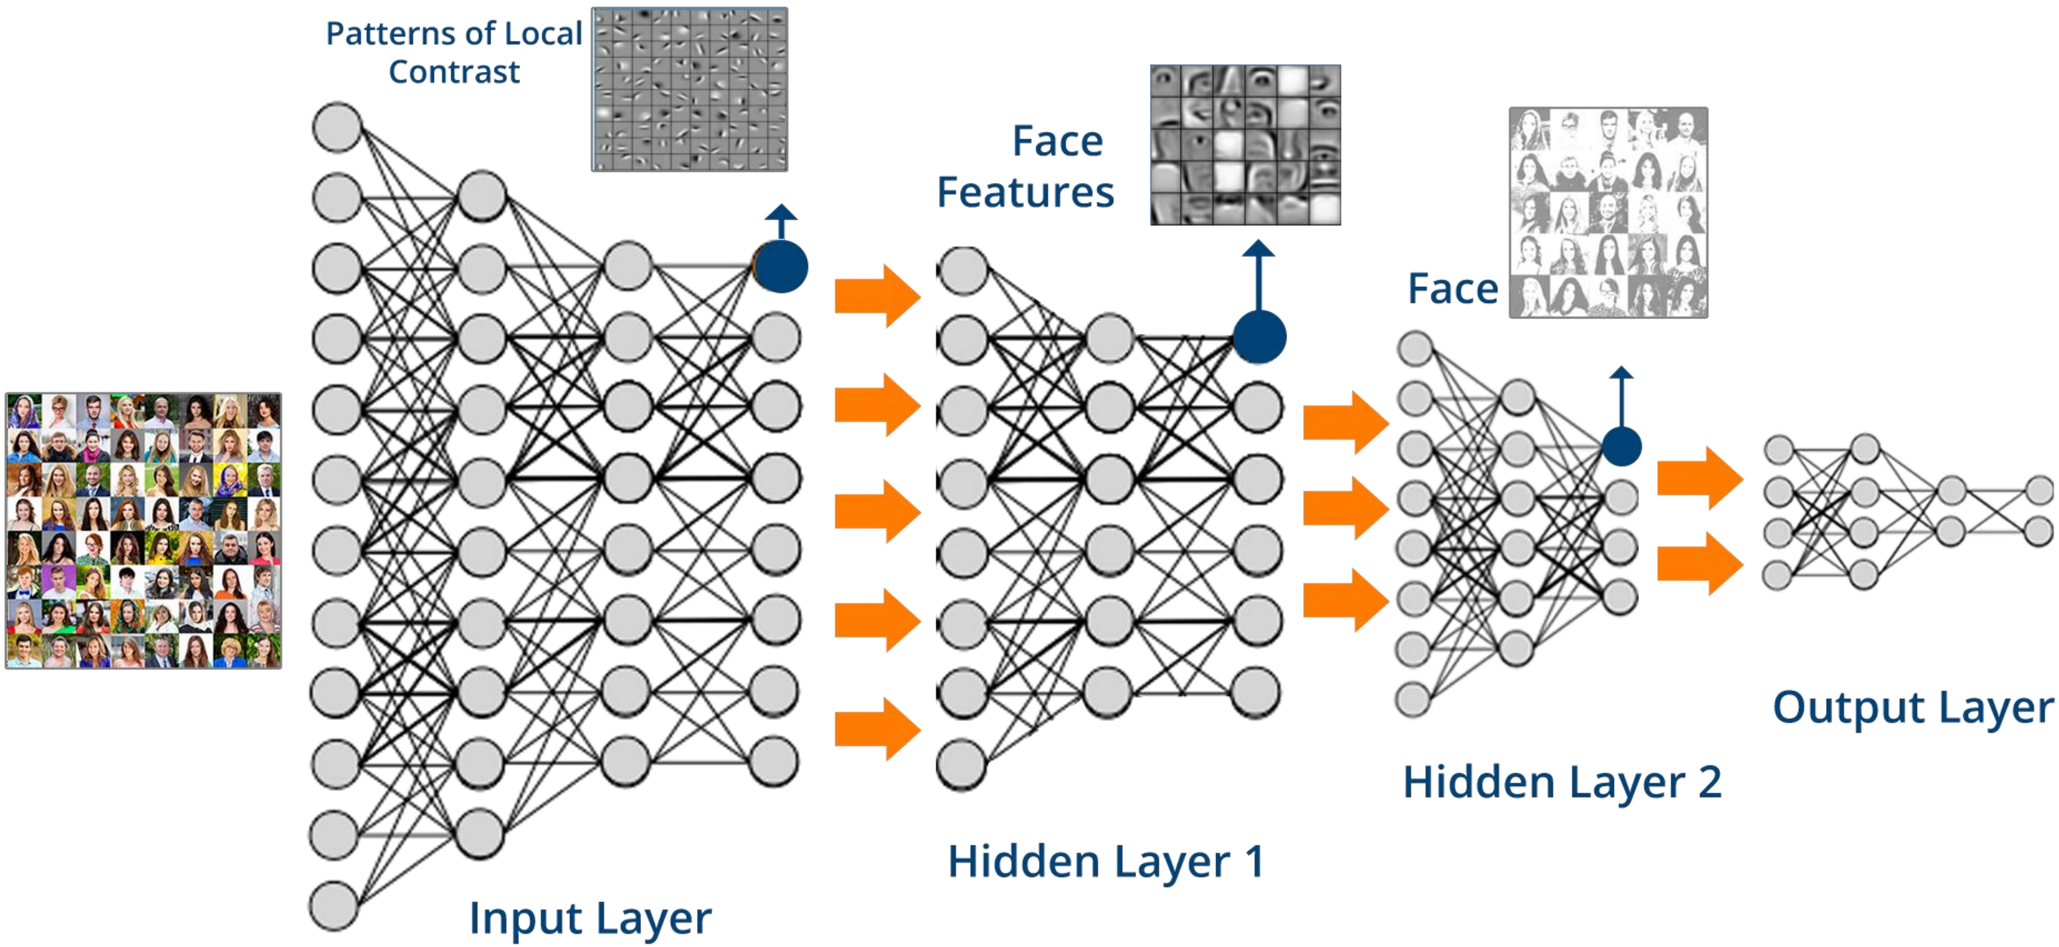

What is Deep Learning? Getting Started With Deep Learning
https://www.edureka.co/blog/what-is-deep-learning

Reconnaissance d'images en temps réel

- La réduction du temps de calcul dépend de :
  - La taille du réseau de neurones influe en fonction
    - Choix du modèle
    - Puissance de calcul
  - Des calculs dans l'image
    - L'intégrale image (notion provenant l'infographie) permet de calculer rapidement les caractéristiques

$$IImage(i,j) = \sum_{k=0}^{i} \sum_{l=0}^{j} Image(k,l)$$

Reconnaissance d’images en temps réel

- Utile pour calculer rapidement des moyennes
- En apprentissage profond, le calcul de moyenne est souvent utilisé

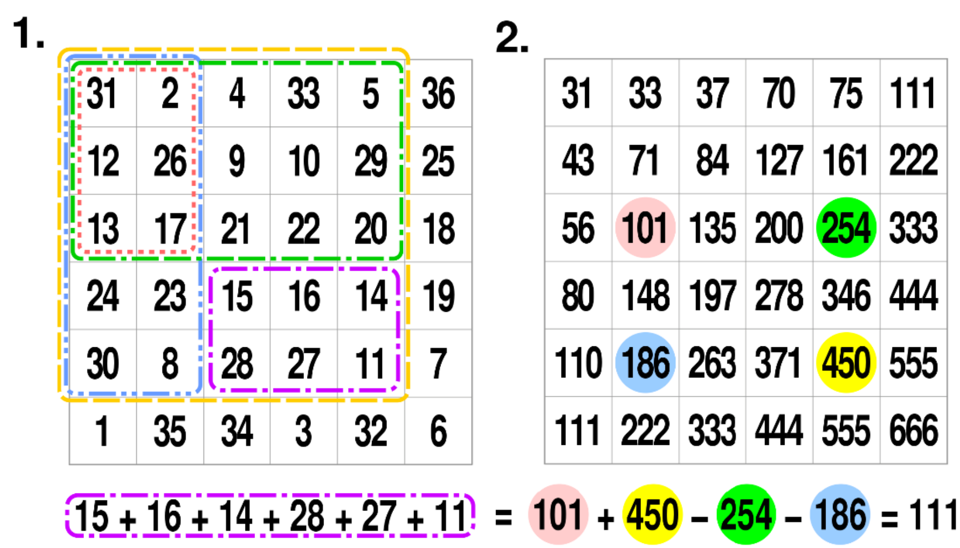

Illustration du gain de calcul avec l’intégrale image

A gauche 5 opérations, à droite 3

Source de l’image en.wikipedia.org Summed-area table

Utilisation de l’intégrale image dans la méthode de Viola et Jones

- L’intégrale image a été introduit par la méthode de Viola et Jones en 2001 pour la détection de visages. Dans cette méthode,
- La méthode utilise des caractéristiques dites pseudo-haar

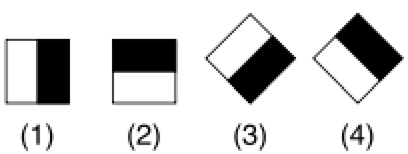

Caractéristiques de détection de bord

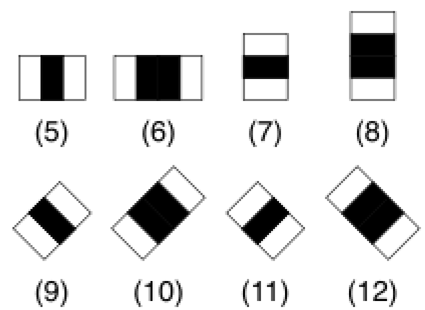

Caractéristiques de détection de lignes

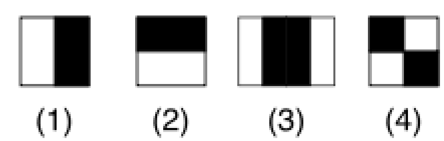

Caractéristiques Viola et Jones pour la détection de visages

Utilisation des Réseaux de Neurones Convolutifs (CNN)

- Krizhevsky et al. (2012) vainqueur de "the ImageNet object recognition challenge“ avec l’algorithme AlexNet du group de recherche SuperVision

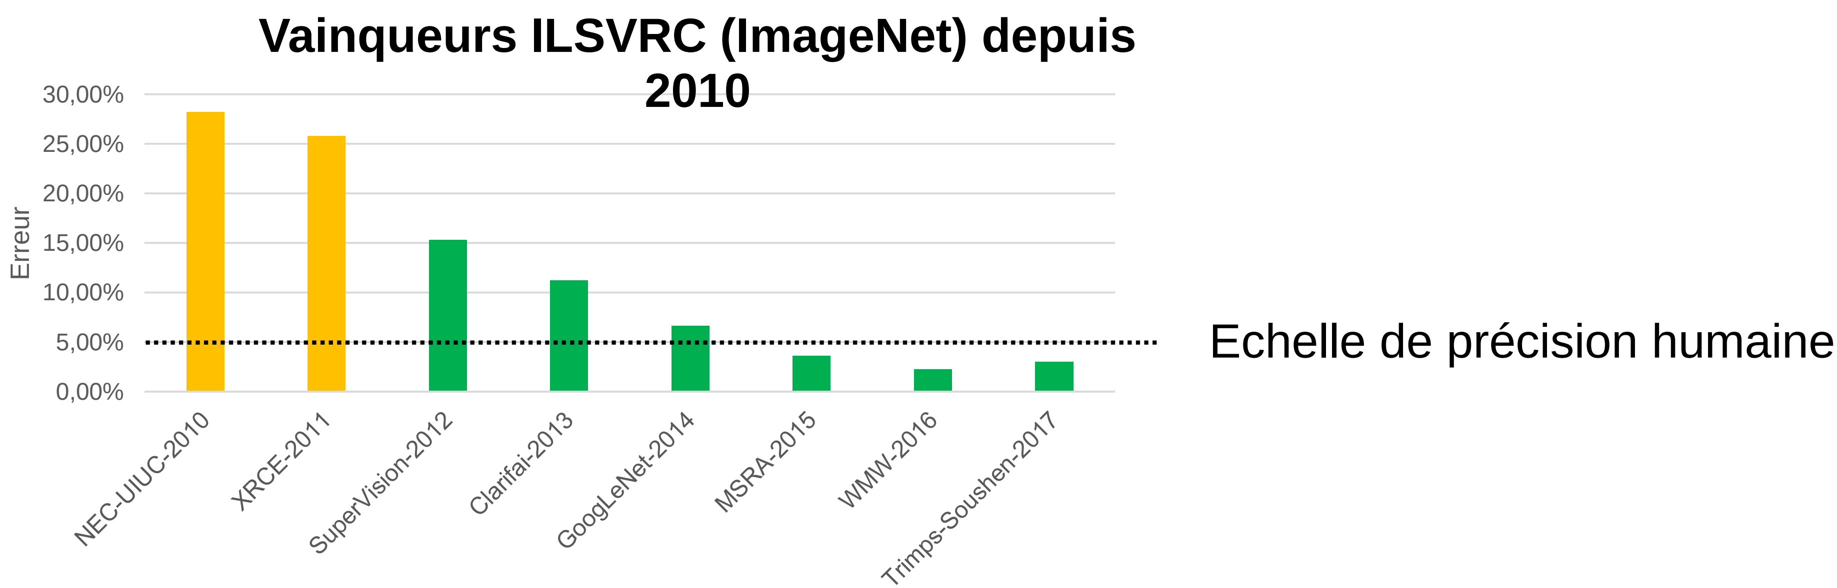

Utilisation des Réseaux de Neurones Convolutifs (CNN)

- Krizhevsky et al. (2012) vainqueur de "the ImageNet object recognition challenge“ avec l’algorithme AlexNet du group de recherche SuperVision

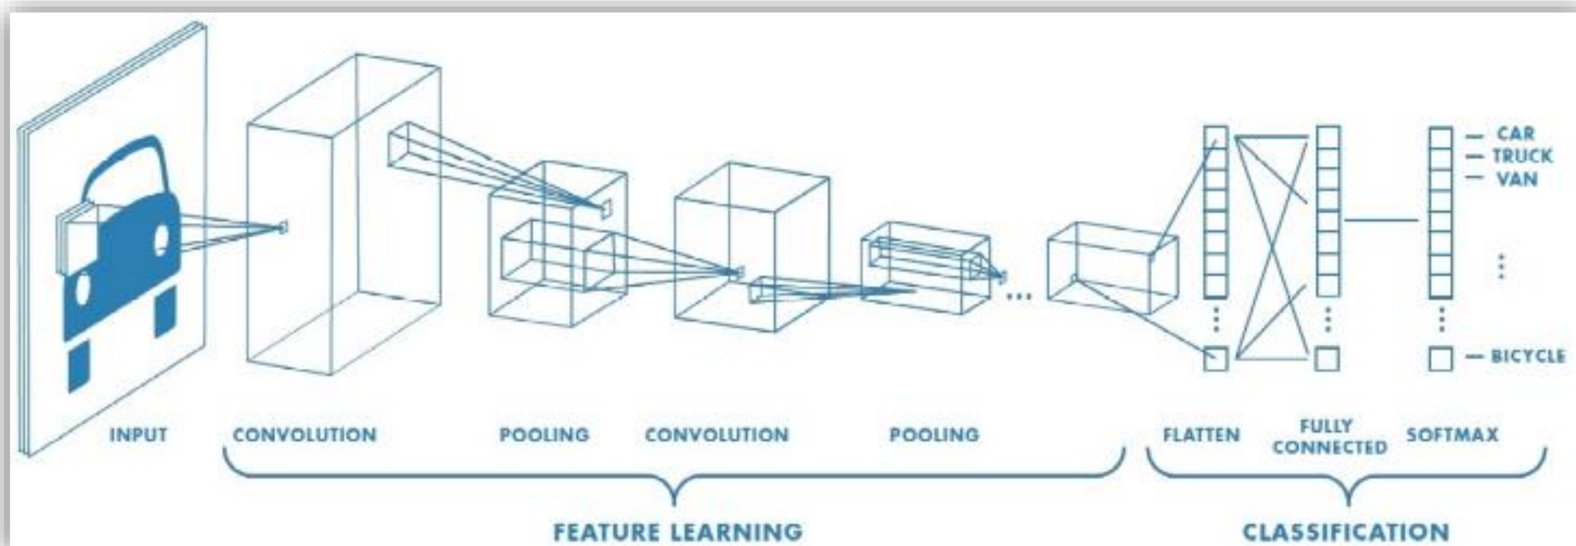

Image de : Trujillo J., Alexandra. (2018). Summarization of video from Feature Extraction Method using Image Processing and Artificial Intelligence.

TP2 détection par pseudo caractéristiques haar

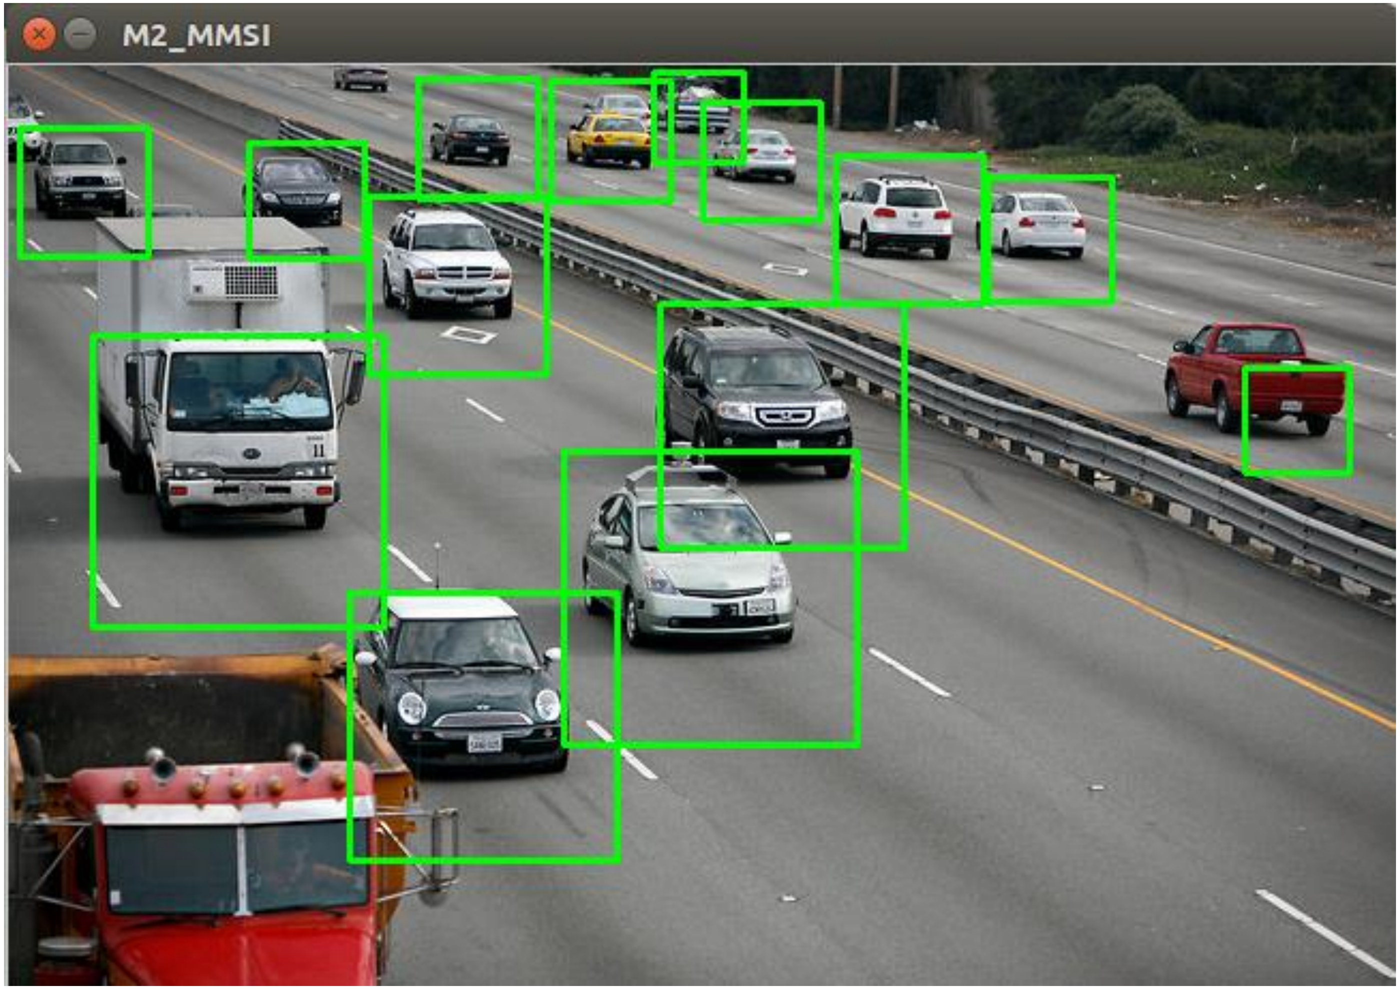

Références

- Jean-Claude Heudin, "Comprendre le Deep Learning: Une introduction aux réseaux de neurones" , des éditions "Sciences-eBook", 2016.
- Olga Russakovsky*, Jia Deng*, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C. Berg and Li Fei-Fei. ImageNet Large Scale Visual Recognition Challenge. *International Journal of Computer Vision*, 2015.
- L. Laporte, R. Flamary, S. Canu, S. Déjean and J. Mothe: Non-convex Regularizations for Feature Selection in Ranking with Sparse SVM, IEEE Transactions on Neural Networks and Learning Systems,25(6) :1118 – 1130, 2014.
- Paul Viola et Michael Jones, « Robust Real-time Object Detection », IJCV, 2001